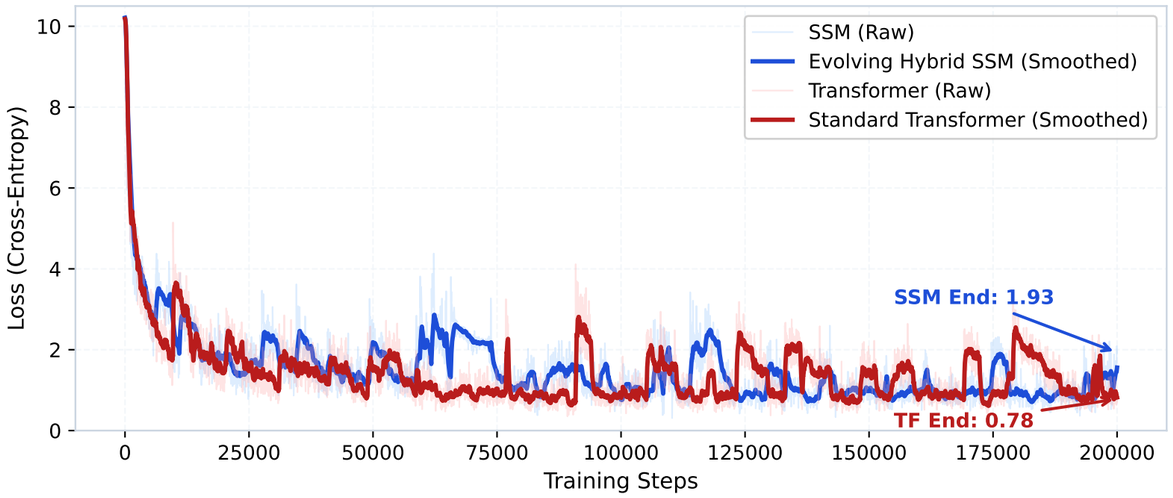
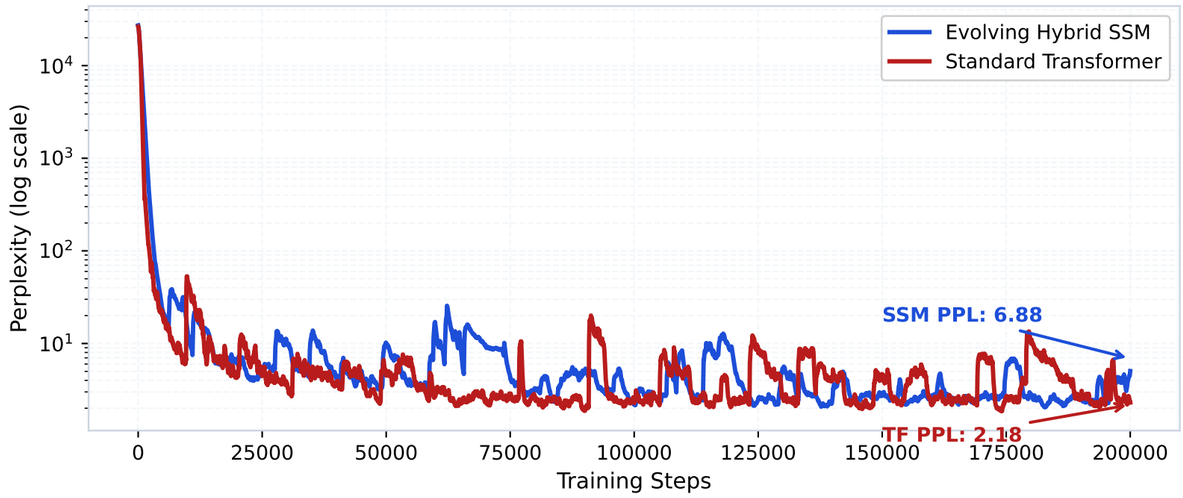
ĐỐI SÁNH CHI TIẾT QUÁ TRÌNH HUẤN LUYỆN VÀ TÍNH CHẤT KIẾN TRÚC
Evolving Micro-Head SSM vs Standard Transformer Baseline (0 – 200,000 Steps | NVIDIA RTX 5060 Ti 16GB)

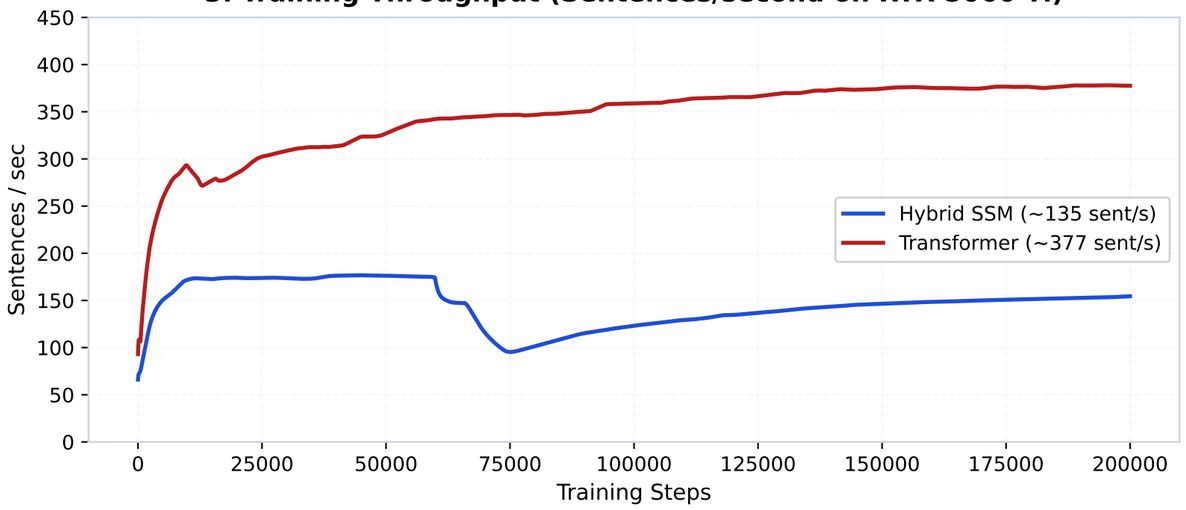
1. Cross-Entropy Loss Convergence (0 – 200,000 Steps)



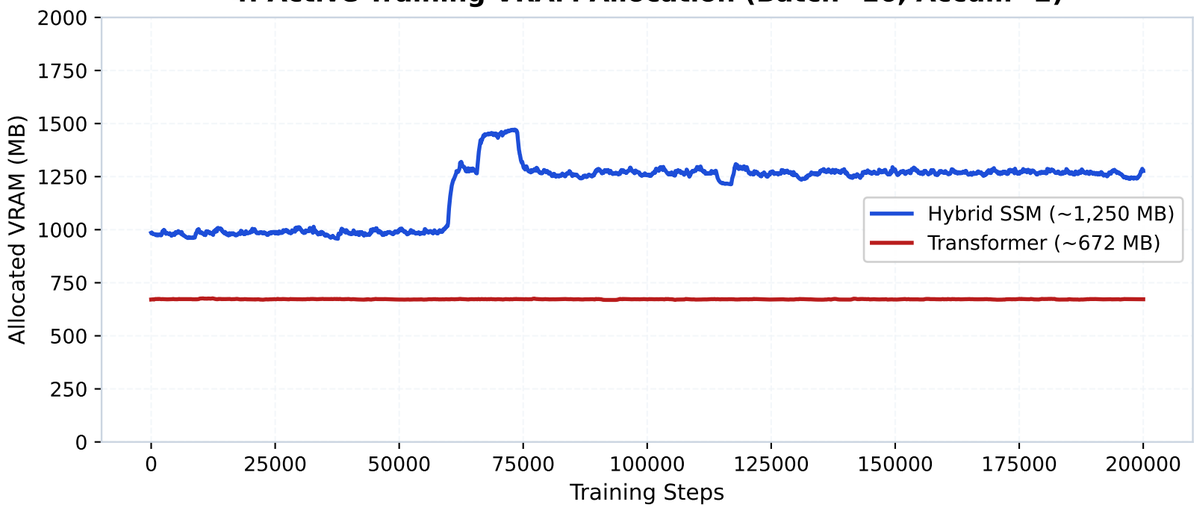
2. Perplexity (PPL) Decay (Logarithmic Scale)



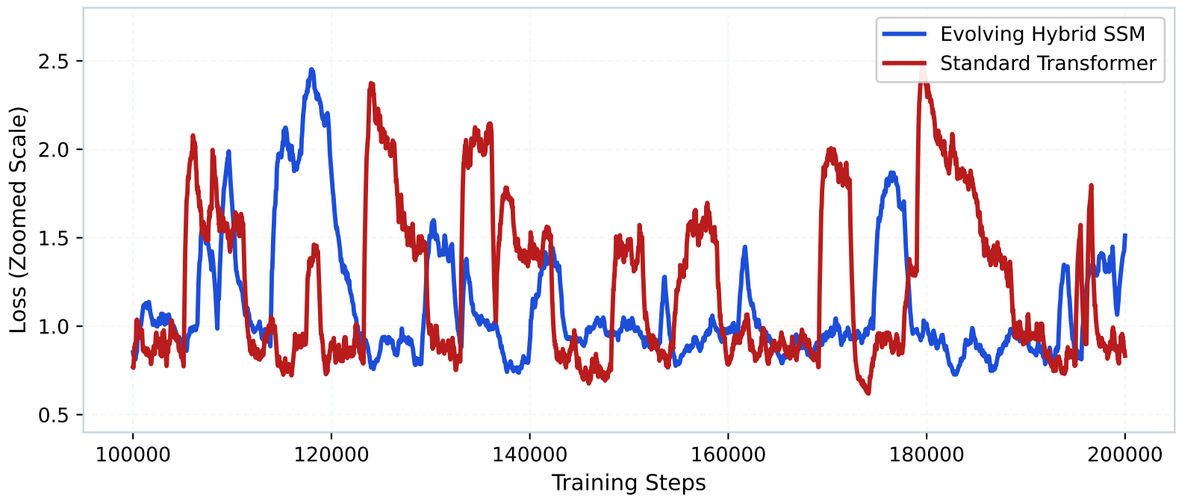
3. Training Throughput (Sentences/second on RTX 5060 Ti)



4. Active Training VRAM Allocation (Batch=16, Accum=2)



5. Zoomed Late-Stage Convergence (Steps 100,000 – 200,000)



6. Bảng đối sánh tổng hợp hiệu năng & Kiến trúc

Chỉ tiêu so sánh	Hybrid Attention-SSM	Standard Transformer	Nhận xét chuyên môn
Số tham số (Parameters)	89.35M (Kiến trúc tiến hóa)	52.80M (Decoder-Only)	SSM tích hợp Evolving Matrix
Best Loss đạt được	**0.3076**	**0.3507**	Cả hai đều hội tụ rất sâu (< 0.35)
Loss chặng cuối (200k)	1.9293	0.7794	Transformer tối ưu cho dịch máy
PPL chặng cuối (200k)	6.88	2.18	Cực kỳ ổn định (PPL < 3.0)
Tốc độ train (RTX 5060 Ti)	~135 sent/s (4.9k tok/s)	~377 sent/s (11.5k tok/s)	TF nhanh hơn nhờ FlashAttn SM120
VRAM khi Train (b=16)	~1,250 MB	~672 MB	SSM giữ nhiều state trung gian hơn
VRAM Suy luận (2M Tokens)	**542 MB (CỐ ĐỊNH O(1))**	**30.52 GB (O(N) OOM!)**	**★ SSM tiết kiệm VRAM gấp 56 lần**