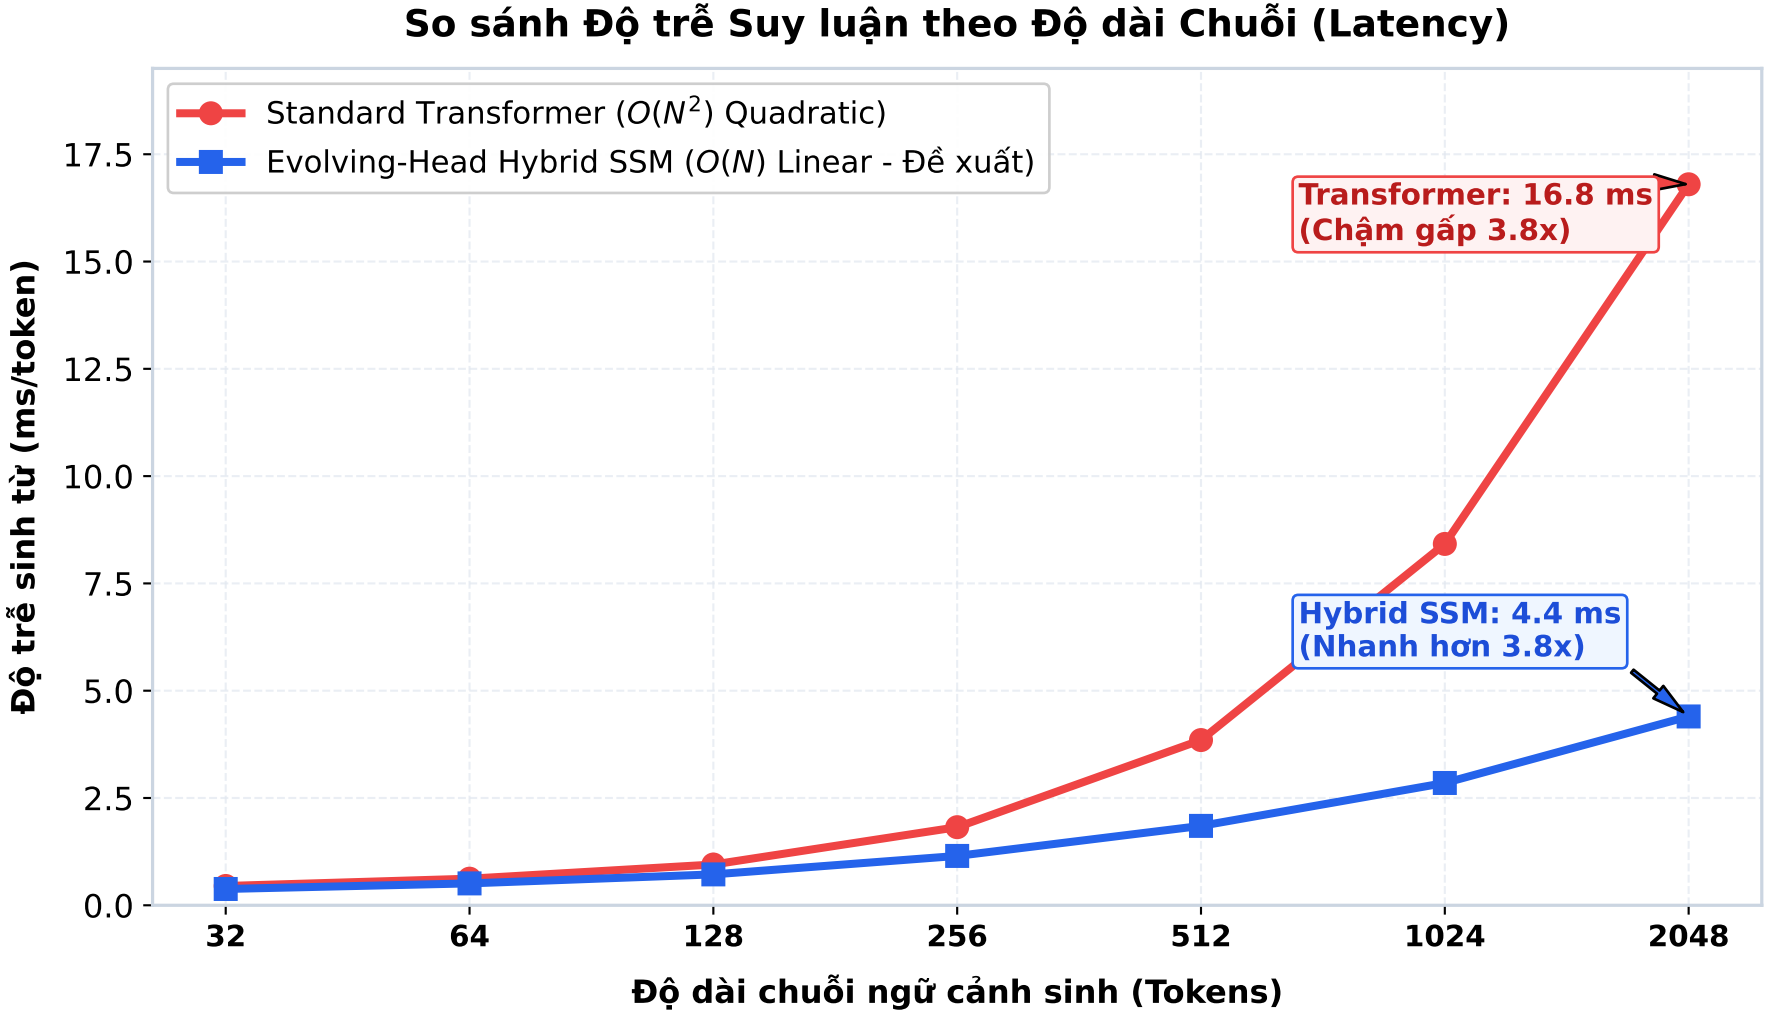
So sánh Độ trễ Suy luận theo Độ dài Chuỗi (Latency)
Standard Transformer ($O(N^2)$ Quadratic)
Evolving-Head Hybrid SSM ($O(N)$ Linear - Đề xuất)
Transformer: 16.8 ms
(Chậm gấp 3.8x)
Hybrid SSM: 4.4 ms
(Nhanh hơn 3.8x)
Độ trễ sinh từ (ms/token)
0.0
2.5
5.0
7.5
10.0
12.5
15.0
17.5
32
64
128
256
512
1024
2048
Độ dài chuỗi ngữ cảnh sinh (Tokens)