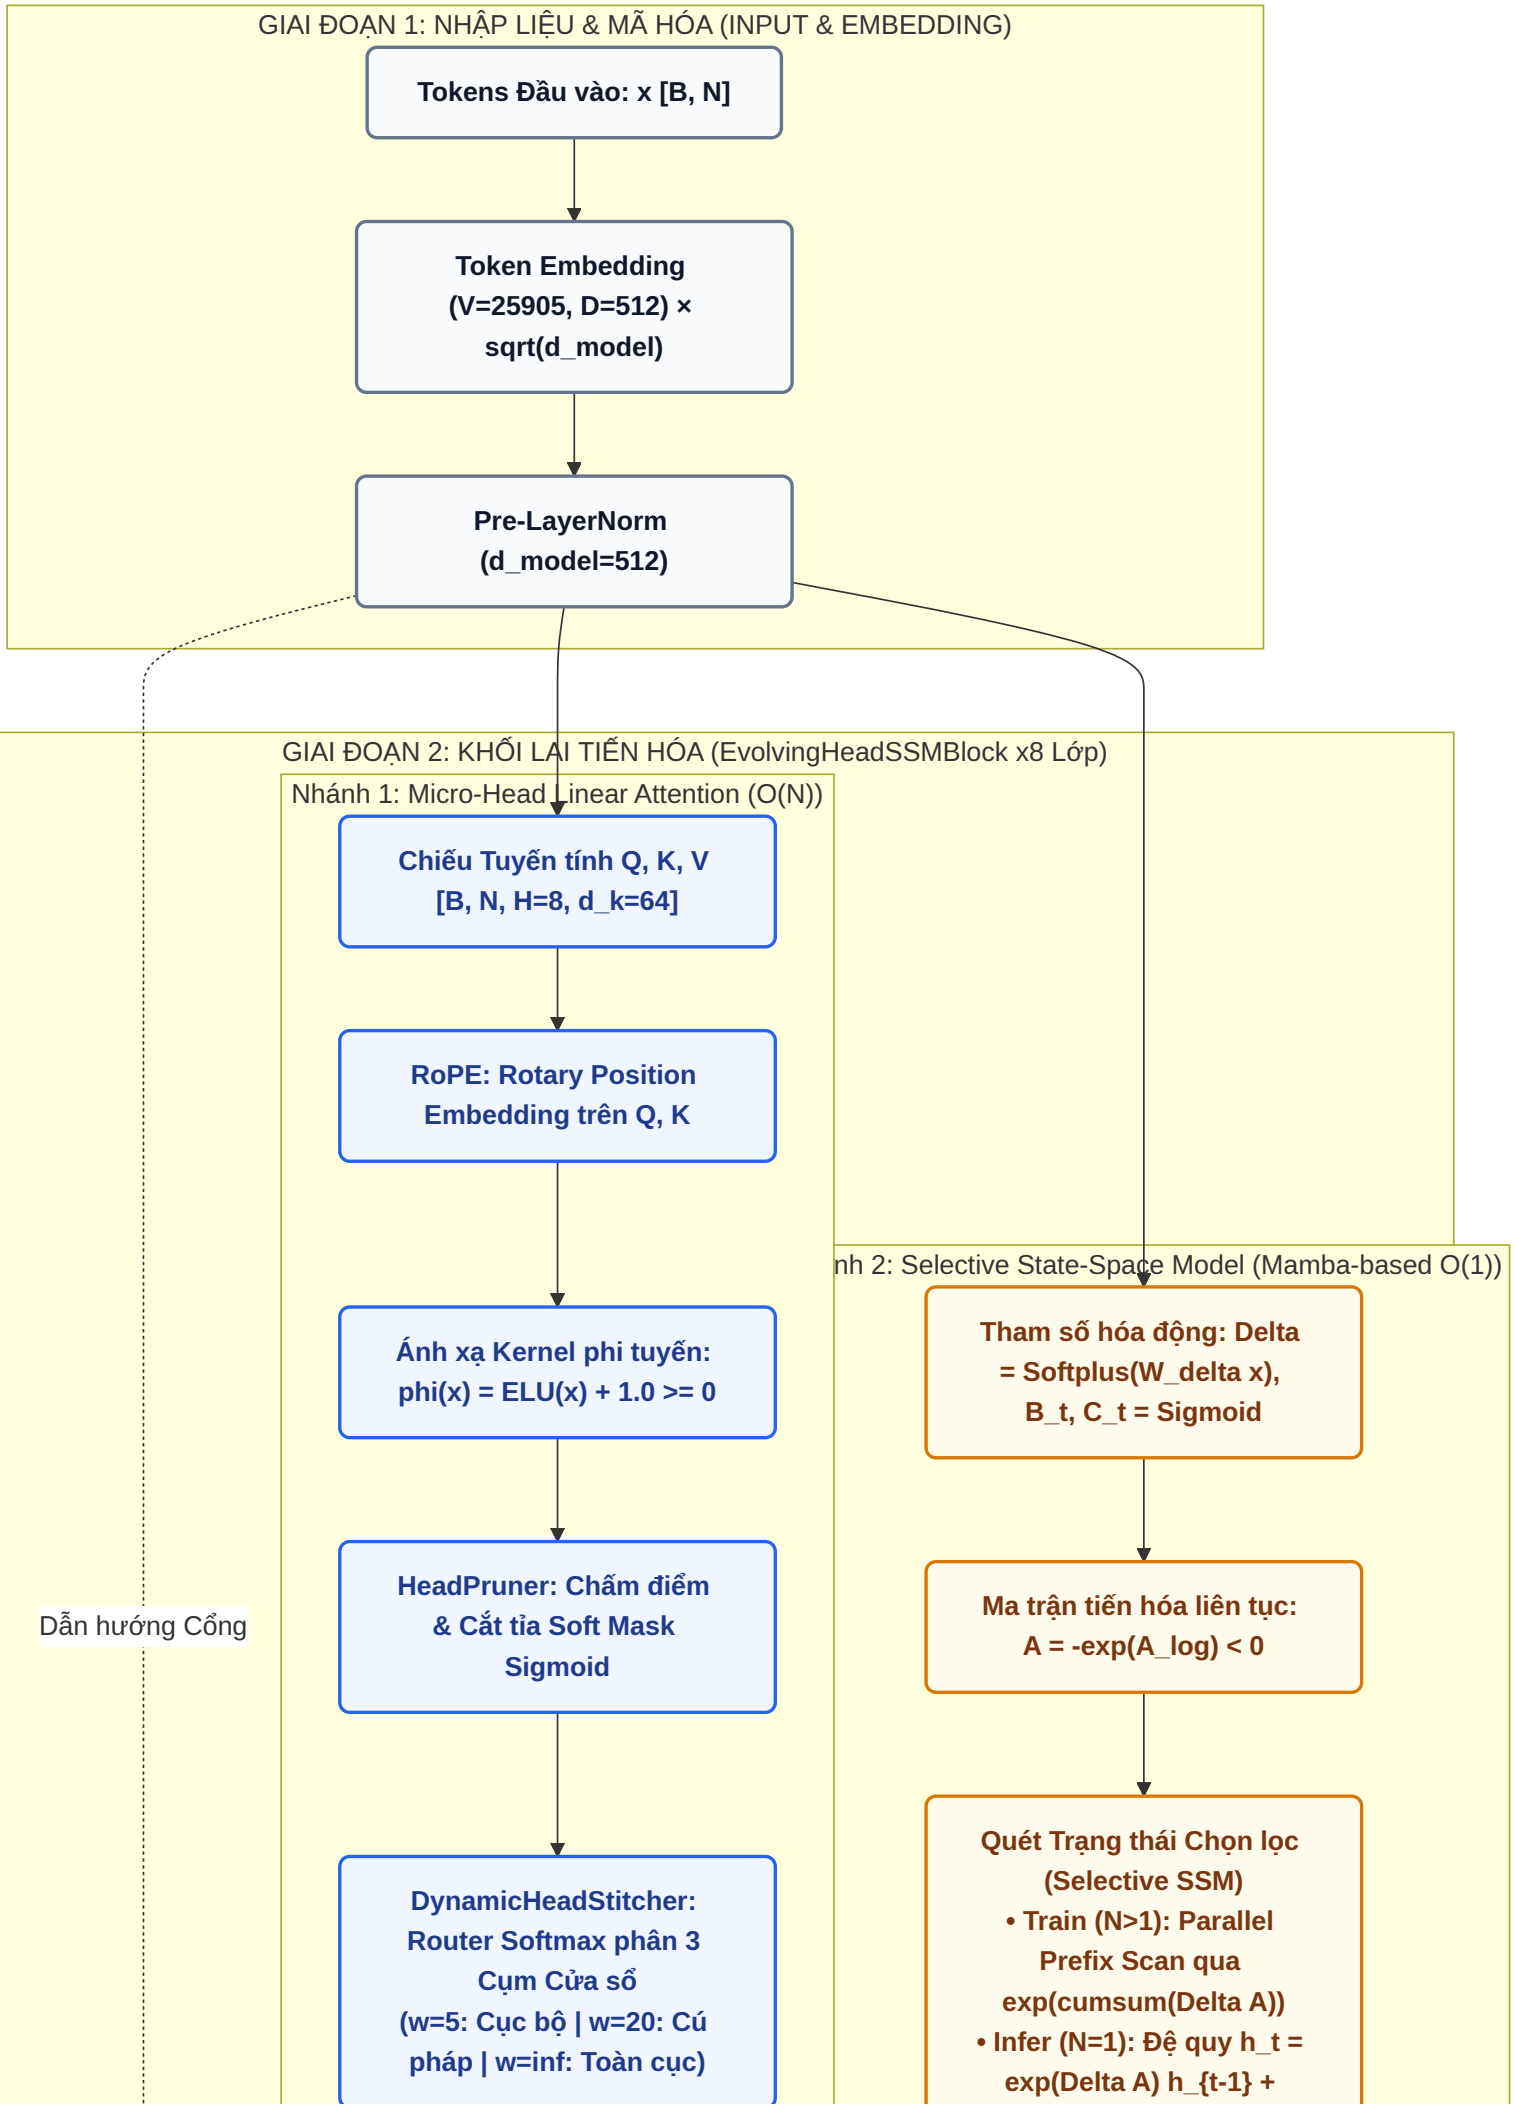
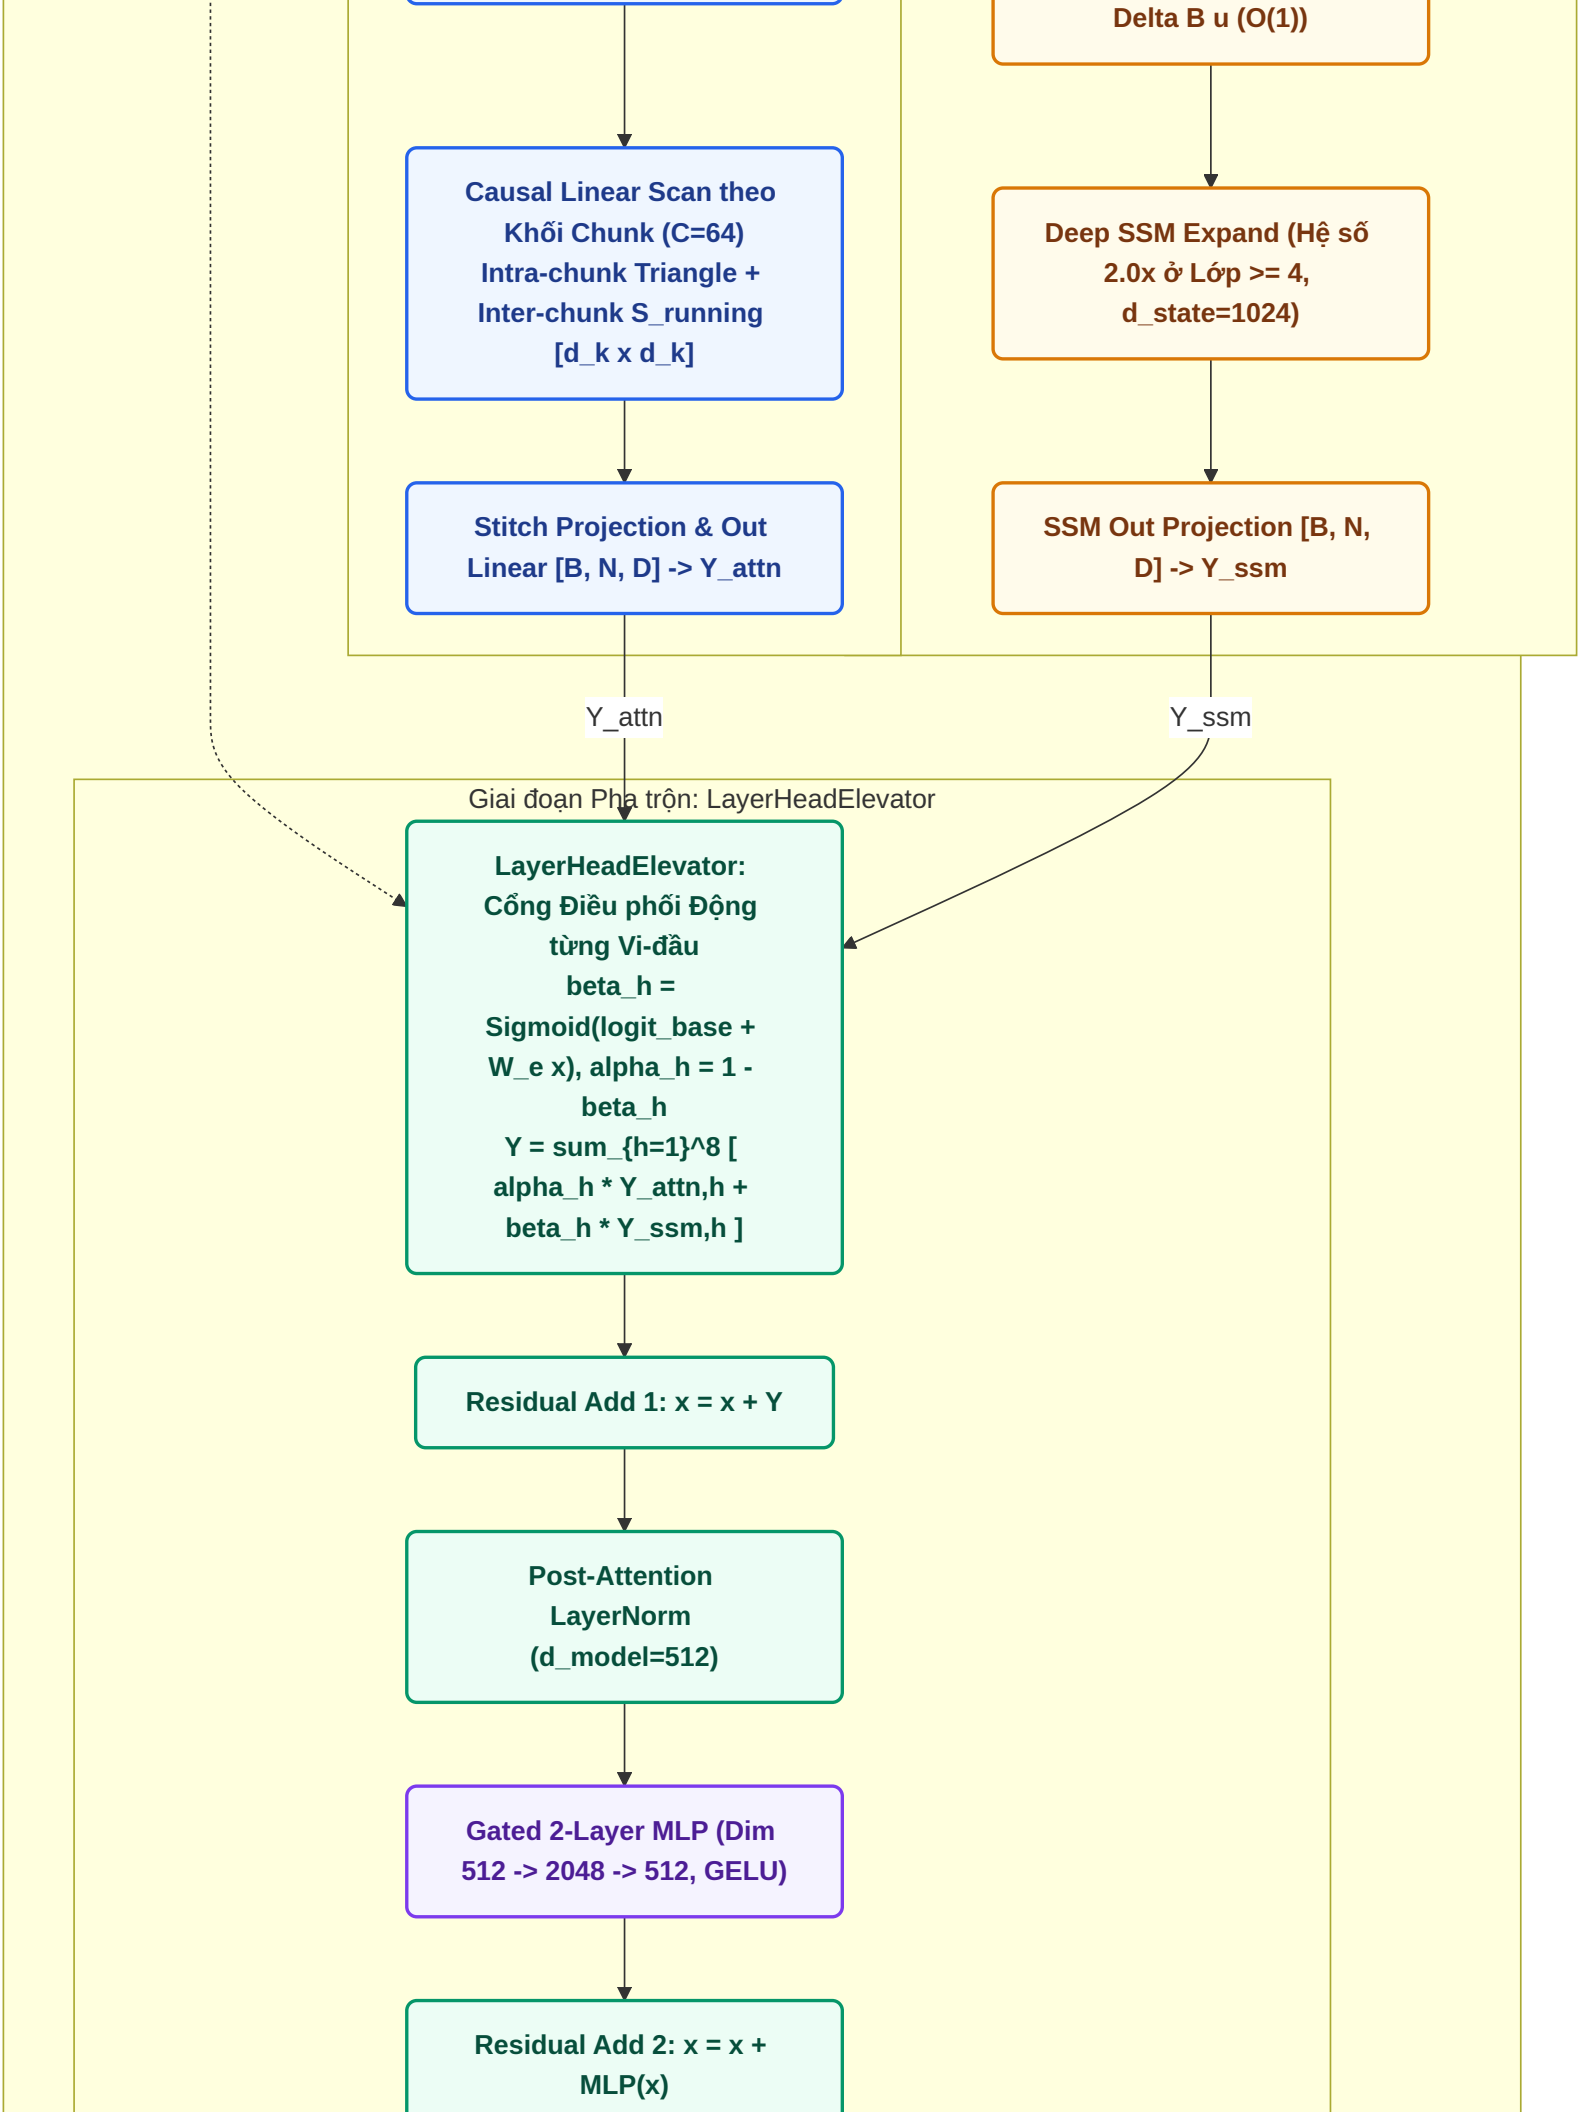
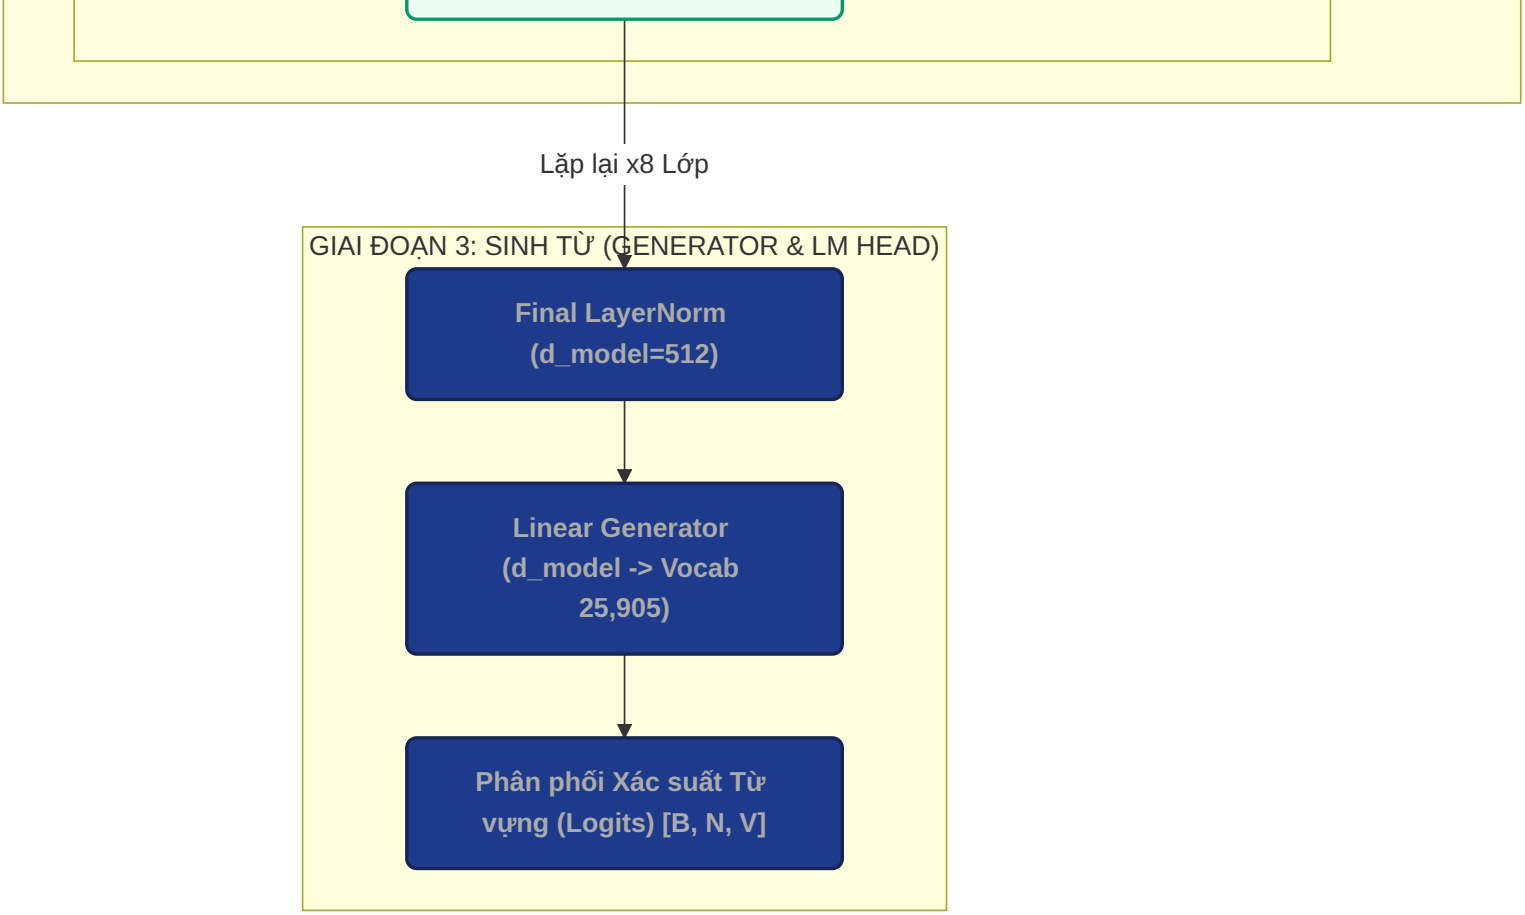

GIAI ĐOẠN 1: NHẬP LIỆU & MÃ HÓA (INPUT & EMBEDDING)
Tokens Đầu vào: x [B, N]
Token Embedding (V=25905, D=512) × sqrt(d_model)
Pre-LayerNorm (d_model=512)
GIAI ĐOẠN 2: KHỐI LAI TIẾN HÓA (EvolvingHeadSSMBlock x8 Lớp)
Nhánh 1: Micro-Head Linear Attention (O(N))
Chiếu Tuyến tính Q, K, V [B, N, H=8, d_k=64]
RoPE: Rotary Position Embedding trên Q, K
Ánh xạ Kernel phi tuyến: phi(x) = ELU(x) + 1.0 >= 0
HeadPruner: Chấm điểm & Cắt tỉa Soft Mask Sigmoid
DynamicHeadStitcher: Router Softmax phân 3 Cụm Cửa sổ (w=5: Cục bộ | w=20: Cú pháp | w=inf: Toàn cục)
nh 2: Selective State-Space Model (Mamba-based O(1))
Tham số hóa động: Delta = Softplus(W_delta x), B_t, C_t = Sigmoid
Ma trận tiến hóa liên tục: A = -exp(A_log) < 0
Quét Trạng thái Chọn lọc (Selective SSM)
• Train (N>1): Parallel Prefix Scan qua exp(cumsum(Delta A))
• Infer (N=1): Đệ quy h_t = exp(Delta A) h_{t-1} +
Dẫn hướng Cổng


Delta B u (O(1))
Causal Linear Scan theo Khối Chunk (C=64) Intra-chunk Triangle + Inter-chunk S_running [d_k x d_k]
Deep SSM Expand (Hệ số 2.0x ở Lớp >= 4, d_state=1024)
Stitch Projection & Out Linear [B, N, D] -> Y_attn
SSM Out Projection [B, N, D] -> Y_ssm
Y_attn
Y_ssm
Giai đoạn Pha trộn: LayerHeadElevator
LayerHeadElevator: Cổng Điều phối Động từng Vi-đầu beta_h = Sigmoid(logit_base + W_e x), alpha_h = 1 - beta_h Y = sum_{h=1}^8 [alpha_h * Y_attn,h + beta_h * Y_ssm,h]
Residual Add 1: x = x + Y
Post-Attention LayerNorm (d_model=512)
Gated 2-Layer MLP (Dim 512 -> 2048 -> 512, GELU)
Residual Add 2: x = x + MLP(x)


Lặp lại x8 Lớp
GIAI ĐOẠN 3: SINH TỪ (GENERATOR & LM HEAD)
Final LayerNorm (d_model=512)
Linear Generator (d_model -> Vocab 25,905)
Phân phối Xác suất Từ vựng (Logits) [B, N, V]