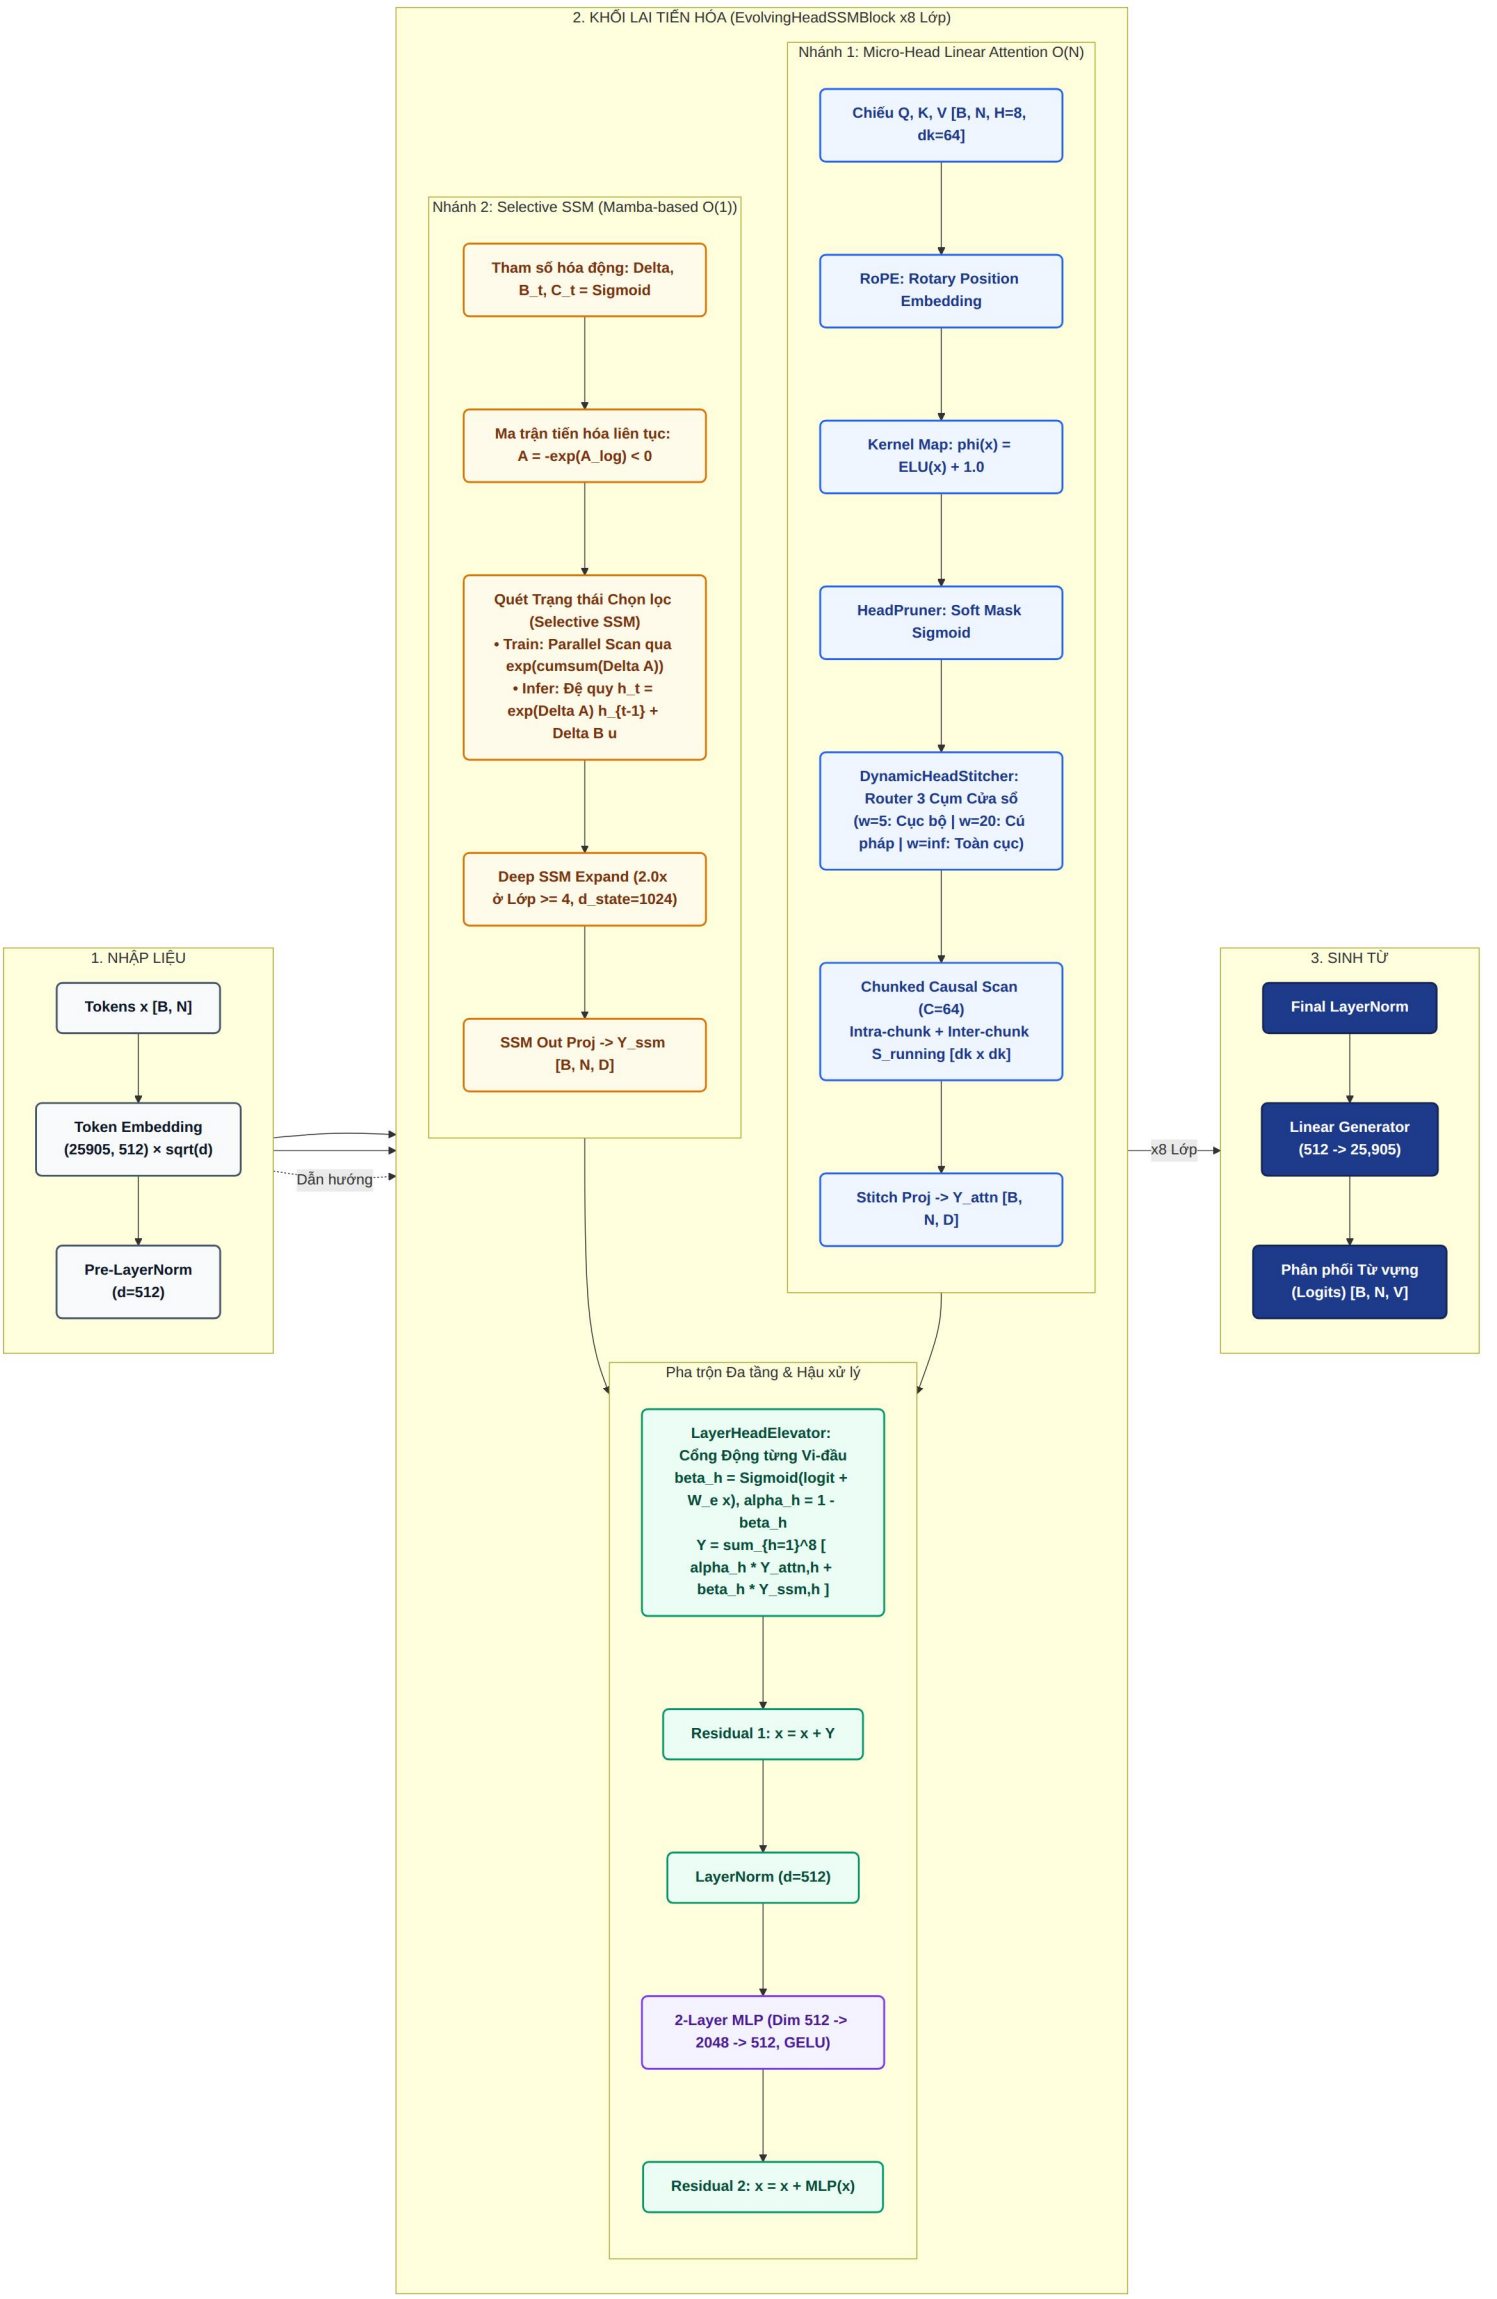

1. NHẬP LIỆU
Tokens x [B, N]
Token Embedding (25905, 512) × sqrt(d)
Pre-LayerNorm (d=512)
Dẫn hướng
2. KHỐI LAI TIẾN HÓA (EvolvingHeadSSMBlock x8 Lớp)
Nhánh 1: Micro-Head Linear Attention O(N)
Chiếu Q, K, V [B, N, H=8, dk=64]
RoPE: Rotary Position Embedding
Kernel Map: phi(x) = ELU(x) + 1.0
HeadPruner: Soft Mask Sigmoid
DynamicHeadStitcher: Router 3 Cụm Cửa sổ (w=5: Cục bộ | w=20: Cú pháp | w=inf: Toàn cục)
Chunked Causal Scan (C=64) Intra-chunk + Inter-chunk S_running [dk x dk]
Stitch Proj -> Y_attn [B, N, D]
Nhánh 2: Selective SSM (Mamba-based O(1))
Tham số hóa động: Delta, B_t, C_t = Sigmoid
Ma trận tiến hóa liên tục: A = -exp(A_log) < 0
Quét Trạng thái Chọn lọc (Selective SSM) • Train: Parallel Scan qua exp(cumsum(Delta A)) • Infer: Đệ quy h_t = exp(Delta A) h_{t-1} + Delta B u
Deep SSM Expand (2.0x ở Lớp >= 4, d_state=1024)
SSM Out Proj -> Y_ssm [B, N, D]
Pha trộn Đa tầng & Hậu xử lý
LayerHeadElevator: Cổng Động từng Vi-đầu beta_h = Sigmoid(logit + W_e x), alpha_h = 1 - beta_h Y = sum_{h=1}^8 [alpha_h * Y_attn,h + beta_h * Y_ssm,h]
Residual 1: x = x + Y
LayerNorm (d=512)
2-Layer MLP (Dim 512 -> 2048 -> 512, GELU)
Residual 2: x = x + MLP(x)
x8 Lớp
3. SINH TỪ
Final LayerNorm
Linear Generator (512 -> 25,905)
Phân phối Từ vựng (Logits) [B, N, V]