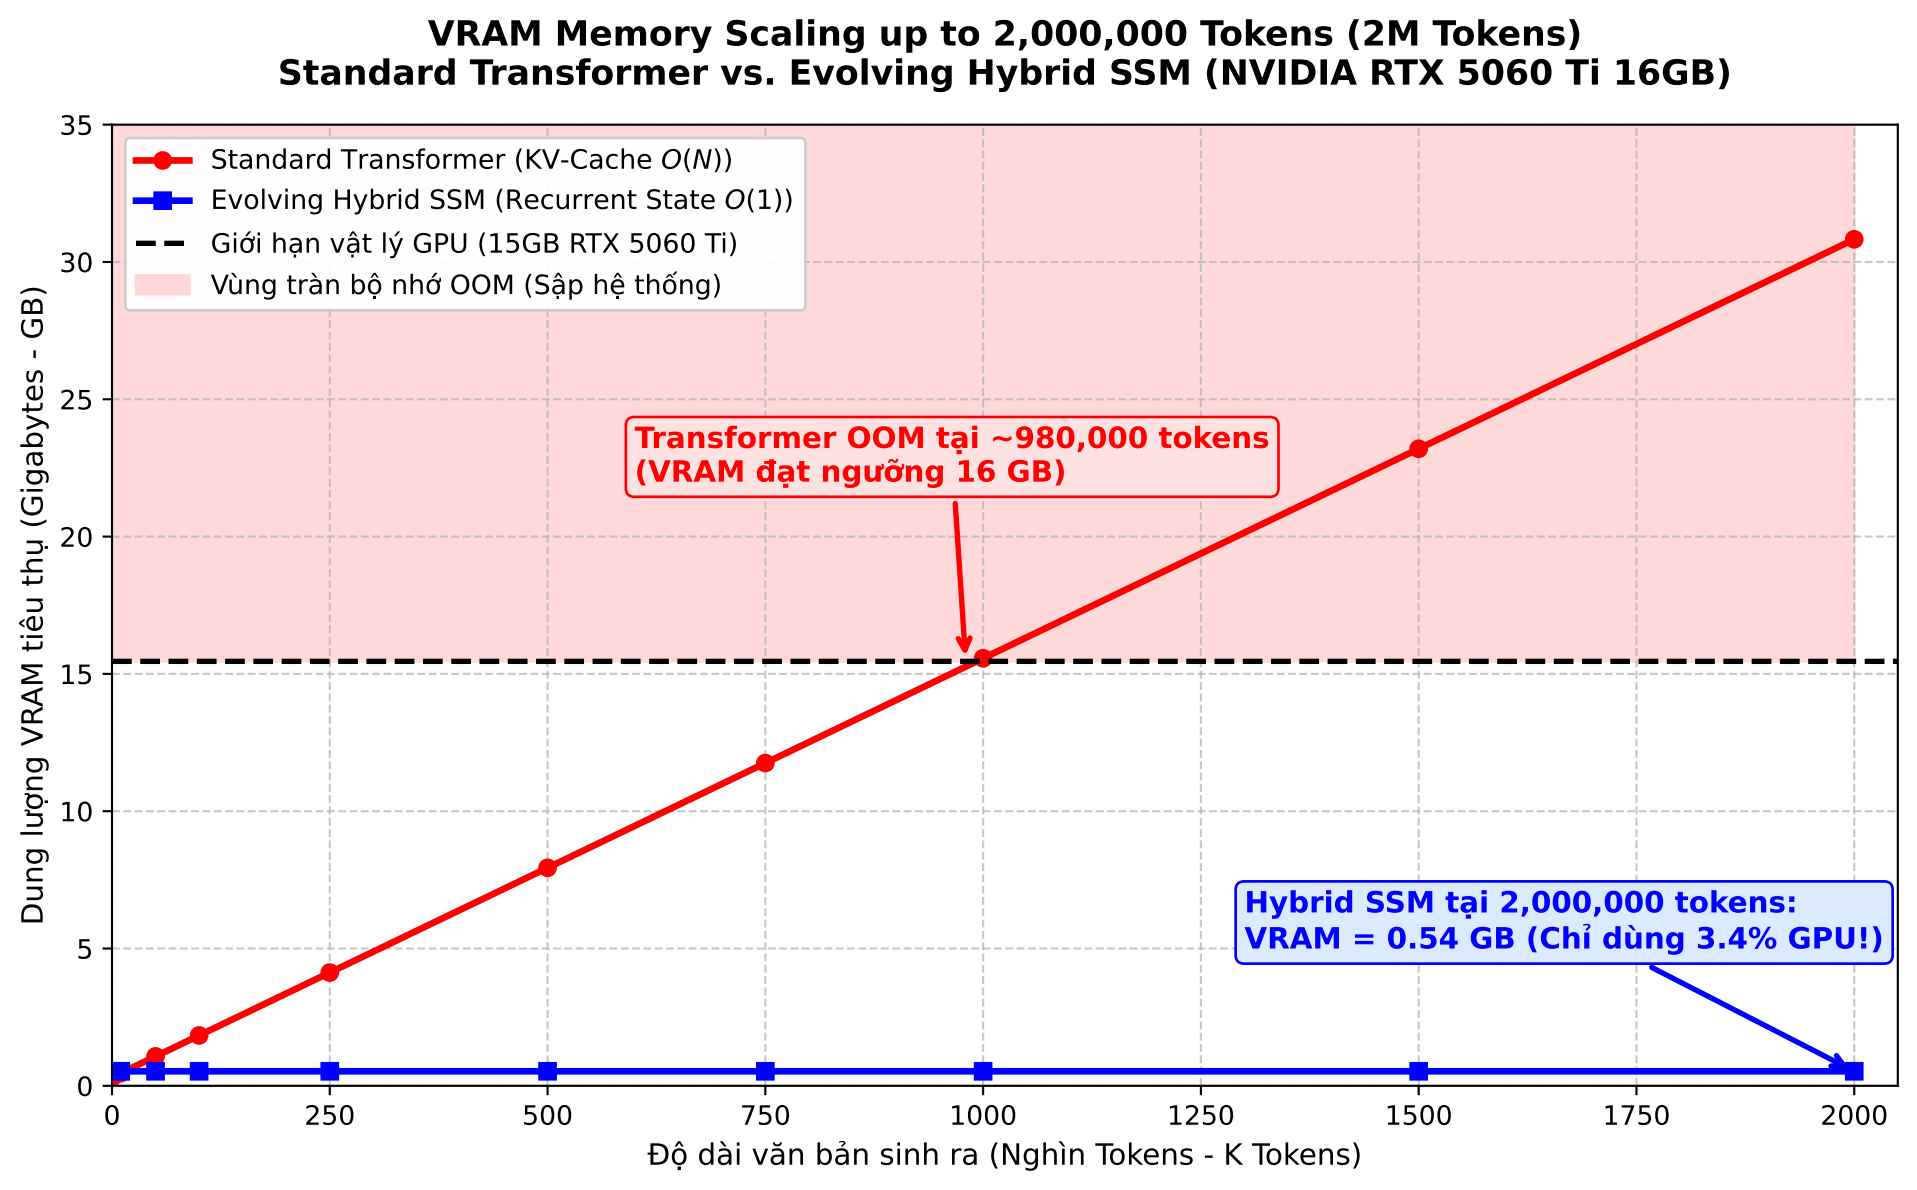
VRAM Memory Scaling up to 2,000,000 Tokens (2M Tokens)
Standard Transformer vs. Evolving Hybrid SSM (NVIDIA RTX 5060 Ti 16GB)
Standard Transformer (KV-Cache O(N))
Evolving Hybrid SSM (Recurrent State O(1))
Giới hạn vật lý GPU (15GB RTX 5060 Ti)
Vùng tràn bộ nhớ OOM (Sập hệ thống)
Transformer OOM tại ~980,000 tokens
(VRAM đạt ngưỡng 16 GB)
Hybrid SSM tại 2,000,000 tokens:
VRAM = 0.54 GB (Chỉ dùng 3.4% GPU!)
Dung lượng VRAM tiêu thụ (Gigabytes - GB)
Độ dài văn bản sinh ra (Nghìn Tokens - K Tokens)
0
5
10
15
20
25
30
35
0
250
500
750
1000
1250
1500
1750
2000