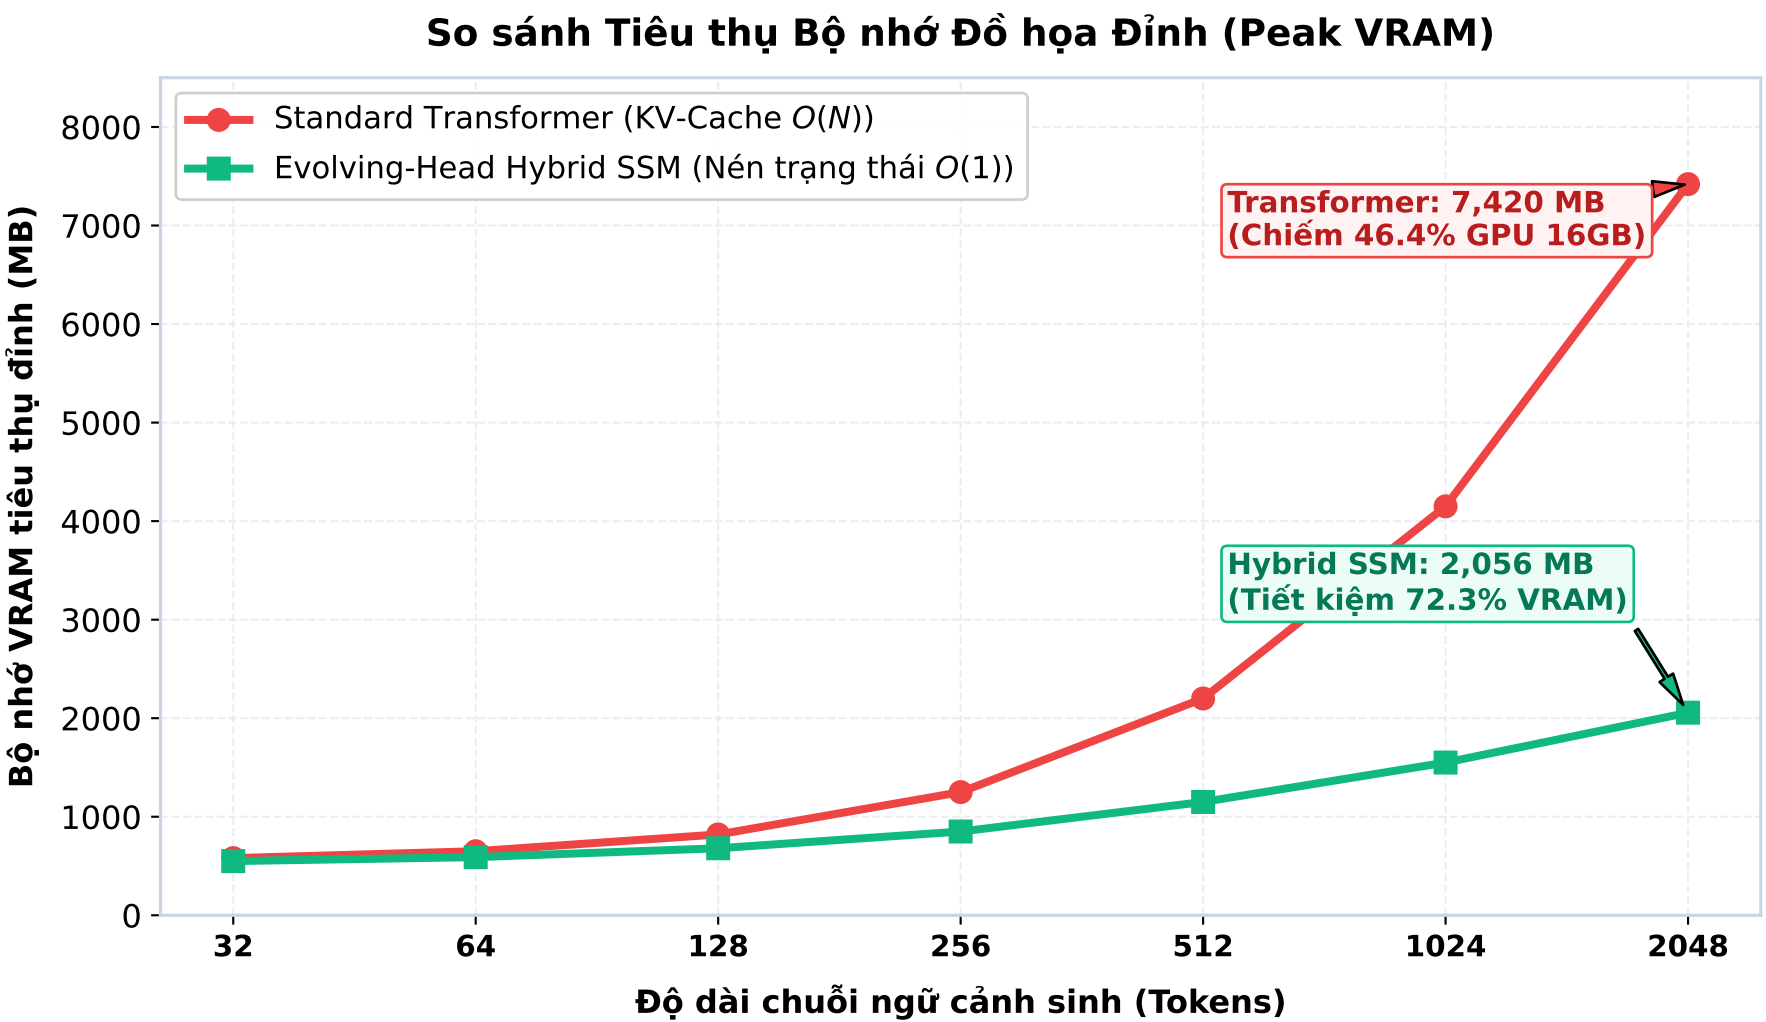
So sánh Tiêu thụ Bộ nhớ Đồ họa Đỉnh (Peak VRAM)
Standard Transformer (KV-Cache O(N))
Evolving-Head Hybrid SSM (Nén trạng thái O(1))
Transformer: 7,420 MB
(Chiếm 46.4% GPU 16GB)
Hybrid SSM: 2,056 MB
(Tiết kiệm 72.3% VRAM)
Bộ nhớ VRAM tiêu thụ đỉnh (MB)
0
1000
2000
3000
4000
5000
6000
7000
8000
32
64
128
256
512
1024
2048
Độ dài chuỗi ngữ cảnh sinh (Tokens)